SP-03 · Reporte cientifico · pima_indians · escenario B

Prototipo académico de investigación (no es un dispositivo médico). Las salidas son riesgos estimados y requieren confirmación clínica.

Tabla 1. Partición 70/15/15 por clase

Clase	Desarrollo	Validación	Prueba	Total
Sin DM2	350	75	75	500
Con DM2	187	39	42	268

Qué muestra: Partición 70/15/15 agrupada y estratificada.

Cómo leerla: Desarrollo: CV anidada y modelo final; Validación: calibración, umbral y conformal; Prueba: evaluación única.

Interpretación: Validación de grupos: PASS.

Limitaciones: La agrupación puede desviar las proporciones en ±1 %.

Tabla 2. CV anidada (AUC externo)

Modelo	Media	DE	IC95 inf	IC95 sup	Brecha optimismo
Reg. logística	0.7332	0.0353	0.6894	0.777	-0.0019
Random Forest	0.7446	0.0475	0.6856	0.8037	-0.009
XGBoost	0.7395	0.0446	0.6841	0.7949	0.0016
TabNet	0.6755	0.0658	0.5937	0.7572	None
Stacking	0.7432	0.0466	0.6853	0.8012	None

Qué muestra: Desempeño del procedimiento (CV anidada 5 externos x 3 internos).

Cómo leerla: Cada AUC externo se obtiene en un pliegue que Optuna nunca vio; la brecha de optimismo es mejor AUC interno menos AUC externo.

Interpretación: lr: 0.7332 ± 0.0353; rf: 0.7446 ± 0.0475; xgb: 0.7395 ± 0.0446; tabnet: 0.6755 ± 0.0658; stack: 0.7432 ± 0.0466

Limitaciones: Estima el procedimiento, no un modelo concreto; IC t con n = 5 es amplio.

Tabla 3. Métricas en prueba aislada

Modelo	roc_auc	pr_auc	sensibilidad	especificidad	vpp	vpn	f1	brier	pendiente	umbral
Reg. logística	0.7648	0.6127	0.7857	0.56	0.5	0.8235	0.6111	0.1892	0.9414	0.26
Random Forest	0.7673	0.6178	0.6667	0.6533	0.5185	0.7778	0.5833	0.1827	1.0264	0.3957
XGBoost	0.7622	0.597	0.7857	0.6267	0.541	0.8393	0.6408	0.1856	1.1672	0.3508
TabNet	0.7667	0.5913	0.8571	0.5867	0.5373	0.88	0.6606	0.1914	0.9272	0.3468
Stacking	0.7689	0.6158	0.8095	0.6133	0.5397	0.8519	0.6476	0.1828	1.0651	0.3274

Qué muestra: Métricas en la prueba aislada (15 %), leída una sola vez.

Cómo leerla: IC 95 % por bootstrap estratificado (B = 2000); el umbral proviene de Validación.

Interpretación: El AUC más alto es de stack (0.7689); ver la tabla de pruebas antes de declarar superioridad.

Limitaciones: Prevalencia de la muestra NHANES no ponderada; no extrapolar VPP/VPN a otras poblaciones.

Tabla 4. Pruebas pareadas en prueba

Par	Dif. AUC	DeLong p	DeLong p Holm	McNemar p Holm
Reg. logística vs Random Forest	-0.0025	0.9363	1.0	1.0
Reg. logística vs XGBoost	0.0025	0.9343	1.0	1.0
Reg. logística vs TabNet	-0.0019	0.9624	1.0	1.0
Reg. logística vs Stacking	-0.0041	0.8628	1.0	1.0
Random Forest vs XGBoost	0.0051	0.5916	1.0	1.0
Random Forest vs TabNet	0.0006	0.9854	1.0	1.0
Random Forest vs Stacking	-0.0016	0.8868	1.0	1.0
XGBoost vs TabNet	-0.0044	0.8993	1.0	1.0
XGBoost vs Stacking	-0.0067	0.4962	1.0	1.0
TabNet vs Stacking	-0.0022	0.9468	1.0	1.0

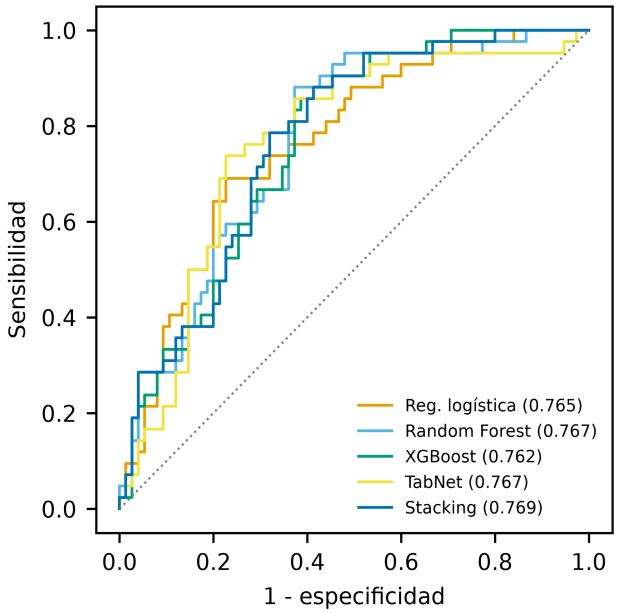
Qué muestra: Comparaciones pareadas en la prueba aislada.

Cómo leerla: DeLong compara AUC sobre los mismos pacientes; McNemar compara aciertos al umbral fijado en Validación; p ajustados por Holm.

Interpretación: No se demostraron diferencias de AUC tras Holm; no se afirma un «mejor modelo».

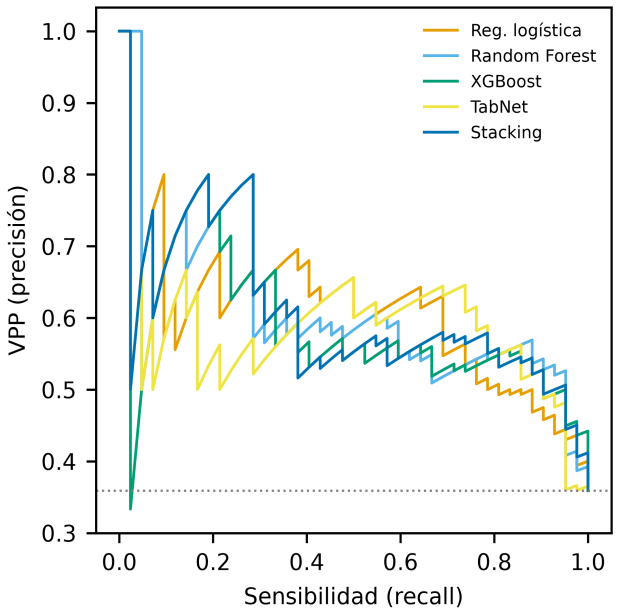
Limitaciones: Una sola partición de prueba; la significancia depende de su tamaño.

Figura 1



Curvas ROC en la prueba aislada. AUC más alto: Stacking (0.769). La diagonal punteada es el azar.

Figura 2



Curvas precisión-sensibilidad. La línea punteada es la prevalencia (0.359), el desempeño de un clasificador sin información.

Figura 3

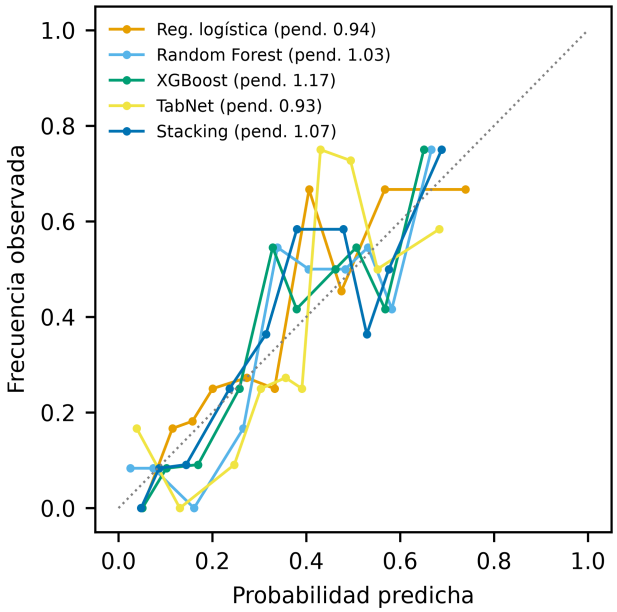
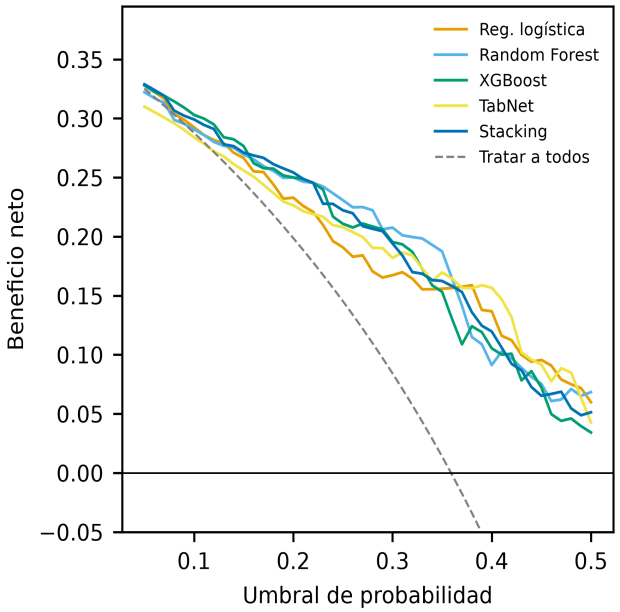


Diagrama de confiabilidad (10 bins por cuantiles) tras calibrar en Validación; la pendiente ideal es 1.

Figura 4



Curva de decisión: un modelo aporta utilidad clínica en los umbrales donde supera a «tratar a todos» y a «ninguno» (0).

Metadatos de reproducibilidad

Cohorte: pima_indians

Escenario: B: Sin glucosa ni insulina

n oficial: 768

SHA-256 datos: c1e0f7d59d2e366cff1ab9fee1796e1e381ea5da64c6d96ef4baabf1eda5f238

Hash índices de prueba: 4b4809ee77c3087e

Semilla: 42

Python: 3.12.15

scikit-learn: 1.9.1

xgboost: 3.4.1

optuna: 5.0.0

Run MLflow: no registrado: The filesystem tracking backend (e.g., './mlruns') is in maintenance mode and will not receive further updates. Please migrate to a database backend (e.g., 'sqlite:///mlflow.db') to access the latest MLflow features. The `mlflow migrate-filestore` tool migrates your existing data losslessly. See https://mlflow.org/docs/latest/self-hosting/migrate-from-file-store for migration guidance. If the filesystem backend is required for your workflow, set `MLFLOW_ALLOW_FILE_STORE=true` to opt out of this exception.

Generado (UTC): 2026-11-12T16:12:20+00:00